Reconocimiento automático de número placas para un gestor automático de estacionamientos en Campus Tecnológico Local San José

Justin Jaffeth Corea Masis

Instituto Tecnológico de Costa Rica

2025

Contenido

1. El problema
2. Solución
   - Detección de placas: YOLO
   - Reconocimiento de placas: OCR
   - Generación sintética de datos
   - Sistema completo: YOLO + OCR
3. Resultados
   - Detección de placas: YOLO
   - Reconocimiento de placas: OCR
   - Sistema completo: YOLO+OCR
4. Conclusiones
5. Recomendaciones

El problema: Parte 1



Figure: Ubicación de los parqueos obtenida mediante Google Maps.

El problema: Parte 2

Ubicación	**Automóviles**	**Motocicletas**
Estacionamiento Interno	12	5
Casa Pacheco	10	0
Estacionamiento City	24	2
Total	**46**	**7**

Table: Número de espacios por estacionamiento.

Solución

Arquitectura del ANPR

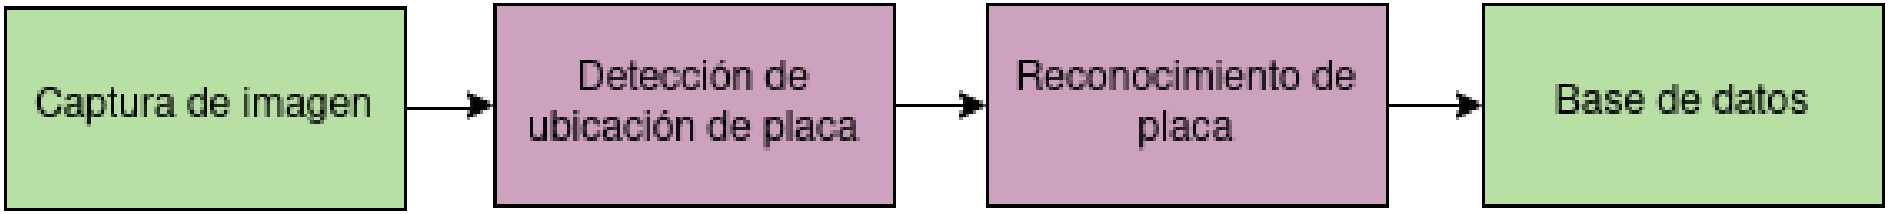


Figure: Diagrama de flujo del sistema ANPR

Solución

Detección de placas: Parte 1

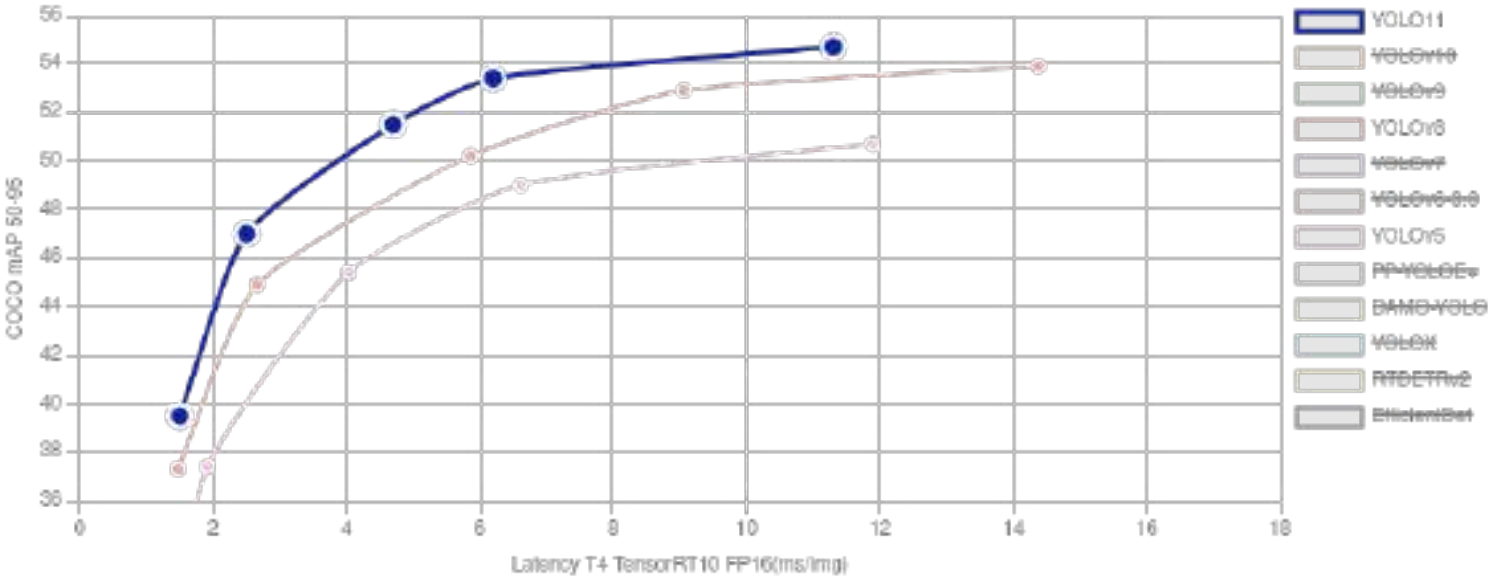


Figure: Comparación de versiones de YOLO.

Solución

Detección de placas: Parte 2

Modelo	**CPU (ms)**	**Parámetros (M)**
YOLO11n	56.1 ± 0.8	2.6
YOLO11s	90.0 ± 1.2	9.4
YOLO11m	183.2 ± 2.0	20.1
YOLO11l	238.6 ± 1.4	25.3
YOLO11x	462.8 ± 6.7	56.9

Table: Comparación de versiones de YOLO11 en CPU.

Solución

Reconocimiento de placas: Parte 1

- Se evaluaron cuatro alternativas: **LPRNet**, **CLPRNet**, **PaddleOCR** y **Fast-Plate-OCR**.
- Criterios considerados:
  - Precisión y velocidad de inferencia.
  - Facilidad de entrenamiento y compatibilidad.
  - Nivel de mantenimiento y soporte del proyecto.

Modelo	**Puntaje ponderado**
LPRNet	29
CLPRNet	33
PaddleOCR	33
Fast-Plate-OCR	**46**

Table: Evaluación comparativa de modelos OCR.

Solución

Reconocimiento de placas: Parte 2

- El análisis ponderado determinó que **Fast-Plate-OCR** obtuvo el mejor desempeño.
- Ventajas principales:
  - Modelo ligero y rápido.
  - Entrenamiento sencillo y reproducible.
  - Compatible con PyTorch y CUDA actuales.
  - Proyecto activo y mantenido.
- Se selecciona **Fast-Plate-OCR (versión XS)** como modelo base para los experimentos.

Solución

Generación sintética de datos: Parte 1

Tipo	Combinación	Ejemplo
Particular	NNNNNN	
Particular	LLL-NNN	
TEC	265 — NN	
TEC	265 — NNN	
Carga ligera	CL — NNNNNN	
Discapacitado	D NNN	
Motocicleta	M NNNNNN	
Motocicleta	M $\frac{\text{NNN}}{\text{NNN}}$	

Table: Posibles combinaciones de caracteres en placas costarricenses. L corresponde a una letra y la N a un dígito numérico.

Solución

Generación sintética de datos: Parte 2

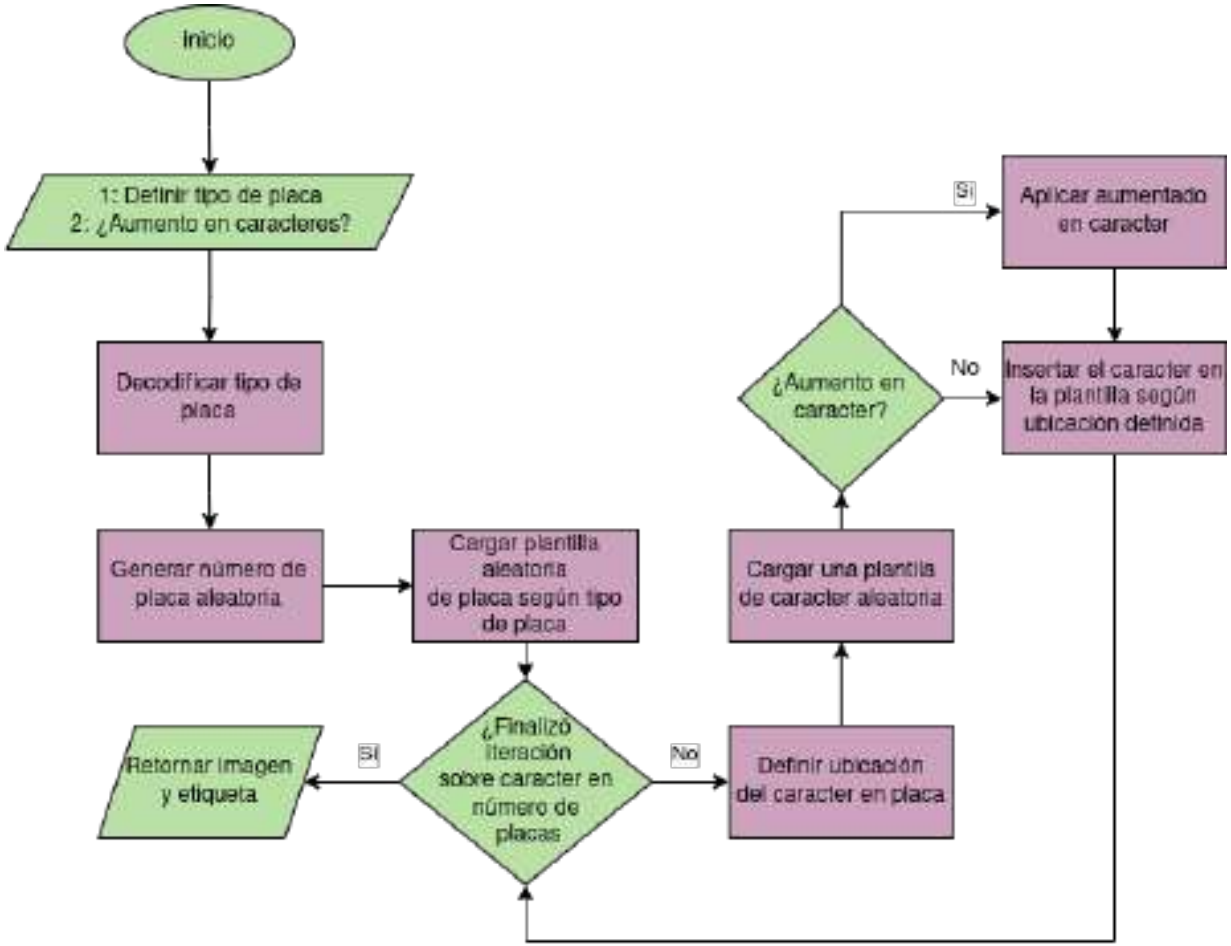


Figure: Generación de imagen de placa sintética.

Solución

Integración del sistema

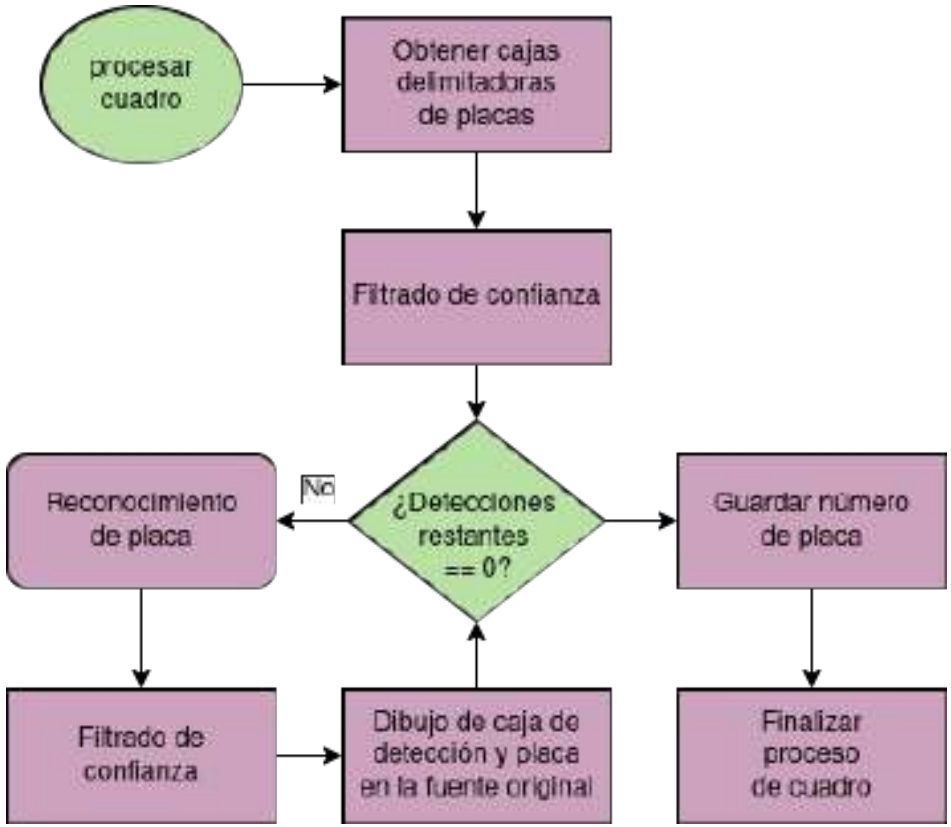


Figure: Diagrama de flujo de funcionamiento de aplicación

Mejor modelo YOLO

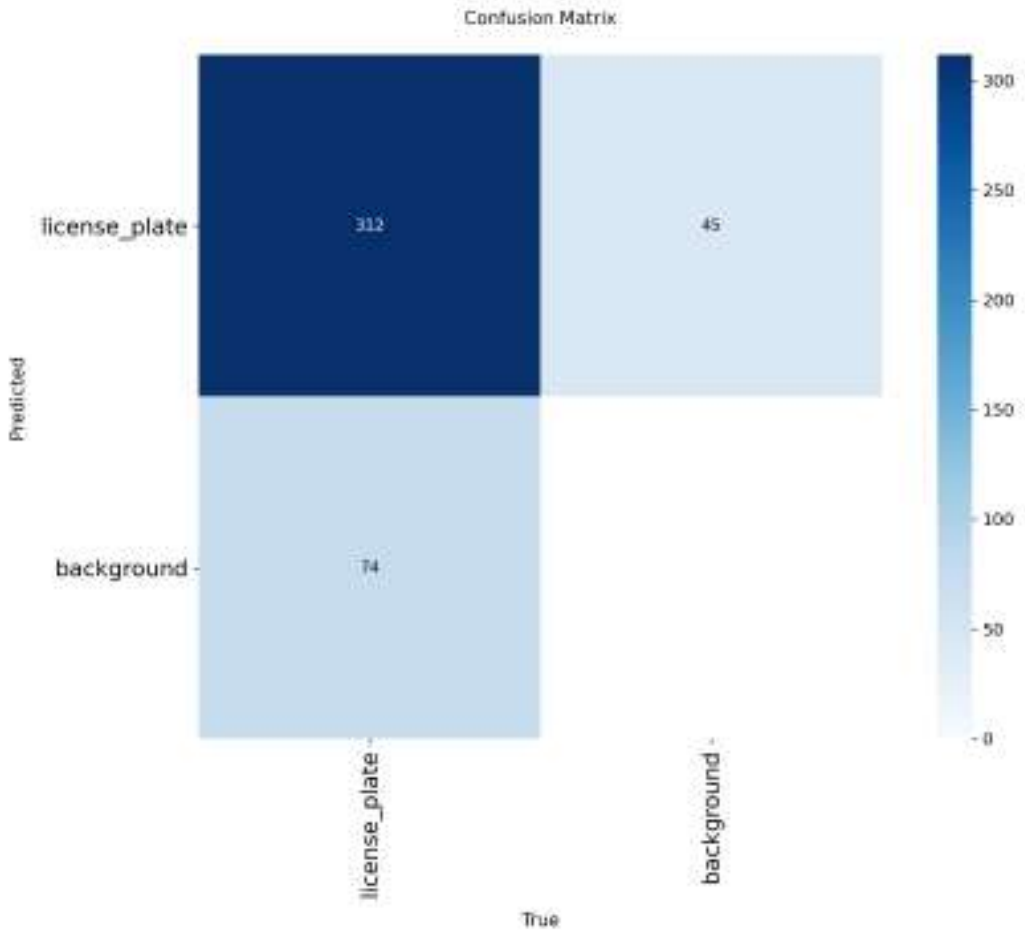


Figure: Matriz de confusión del mejor experimento

Análisis de fallos YOLO

Falso positivo por ausencia de etiqueta: parte 1



(a) Detección de placa falsa positiva en segundo auto blanco



(b) Detección de placa falsa positiva en auto negro al fondo

Figure: Ejemplos de falsos positivos de detección de placas

Análisis de fallos YOLO

Falso positivo por ausencia de etiqueta: parte 2



(a) Detección de placa falsa positiva en auto trasero de la derecha



(b) Detección de placa falsa positiva en auto de la izquierda

Figure: Ejemplos de falsos positivos de detección de placas

Análisis de fallos YOLO

Falso negativo



(a) No detección de placa en auto trasero de la izquierda



(b) No detección de placa en auto lejano

Figure: Ejemplos de falsos negativos de detección de placas

Análisis de fallos YOLO

Falso positivo por detección errónea



(a) Confusión de QR con una placa vehicular

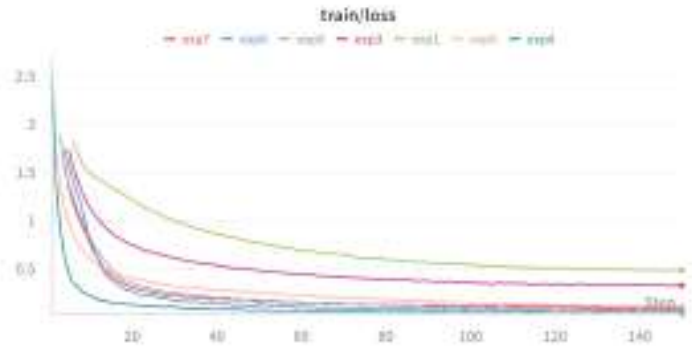
Figure: Ejemplo de falsos positivos completo

Comparación de resultados YOLO

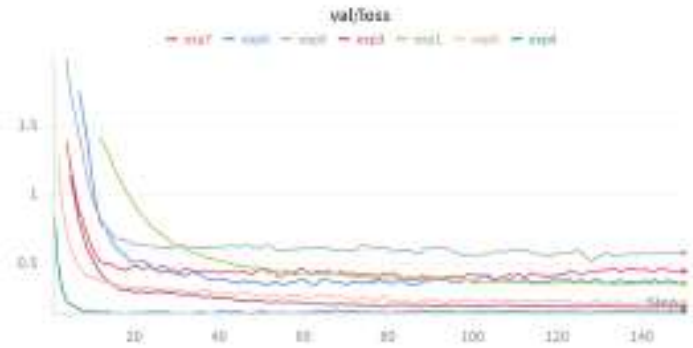
Modelo	**Precisión**	**Exhaustividad**	**mAP**
YOLO sin ajuste	0	0	0
Modelo base	0.811	0.703	0.814
YOLO propuesto (Conjunto 3)	0.935	0.806	0.946

Table: Comparación de desempeño entre el modelo base y el modelo YOLO propuesto.

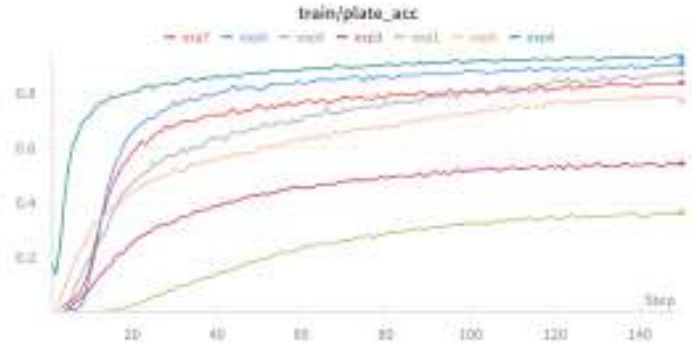
Mejor modelo OCR inicial



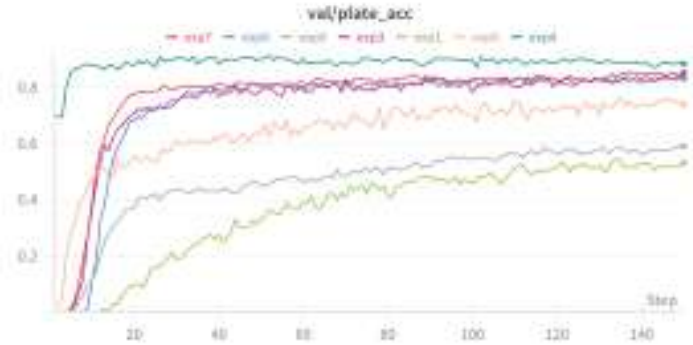
(a) Función de pérdida en conjunto de entrenamiento



(b) Función de pérdida en conjunto de validación



(c) Precisión de reconocimiento de placa en conjunto de entrenamiento



(d) Precisión de reconocimiento de placa en conjunto de validación

Figure: Métricas de aprendizaje en primer conjunto de experimentos

Resultado mejor modelo OCR inicial

Hiperparámetros del entrenamiento

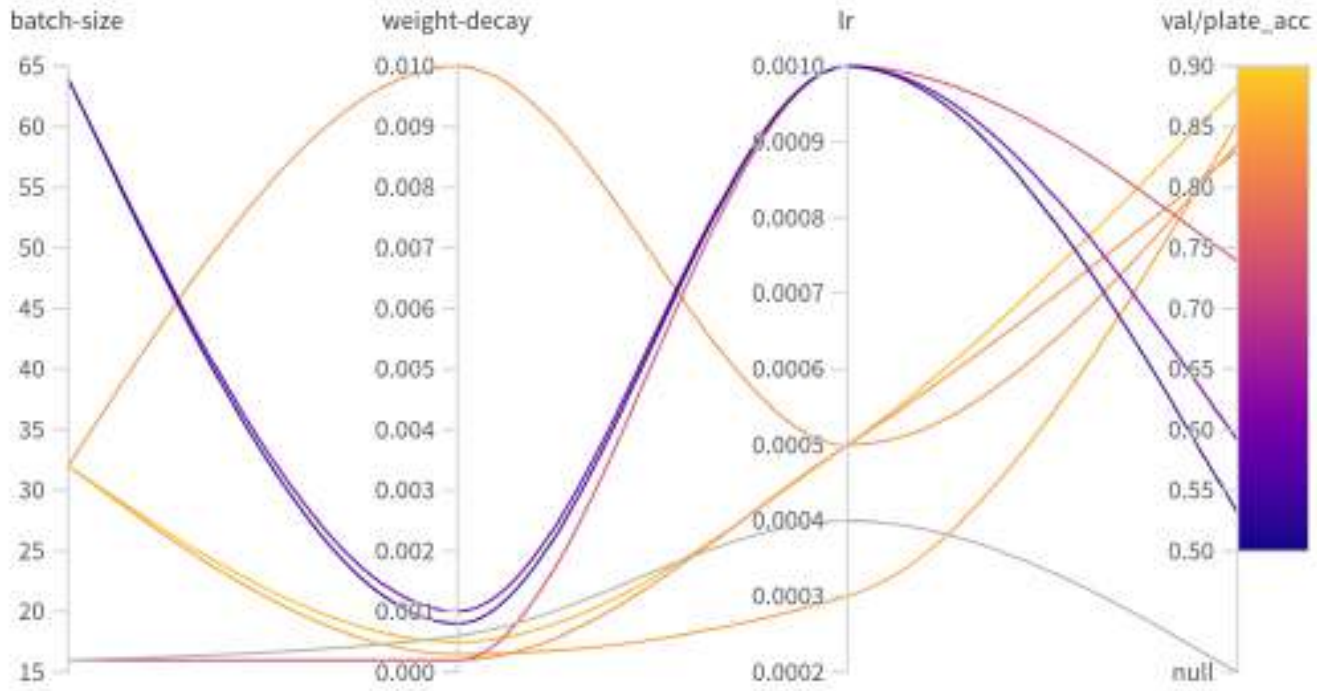


Figure: Hiperparámetros del entrenamiento contra precisión de reconocimiento de placa

Resultado mejor modelo OCR inicial

Hiperparámetros de la entrada

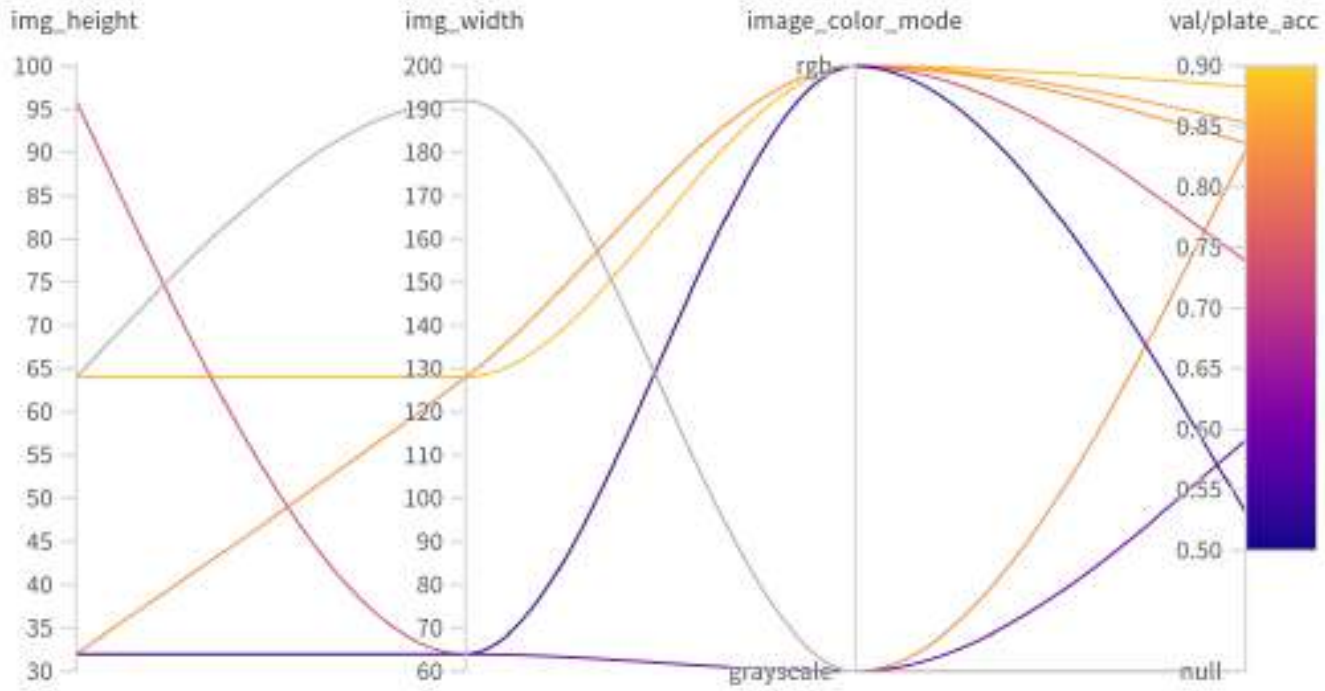


Figure: Hiperparámetros de la imagen contra precisión de reconocimiento de placa

Resultado mejor modelo OCR inicial

Hiperparámetros del modelo

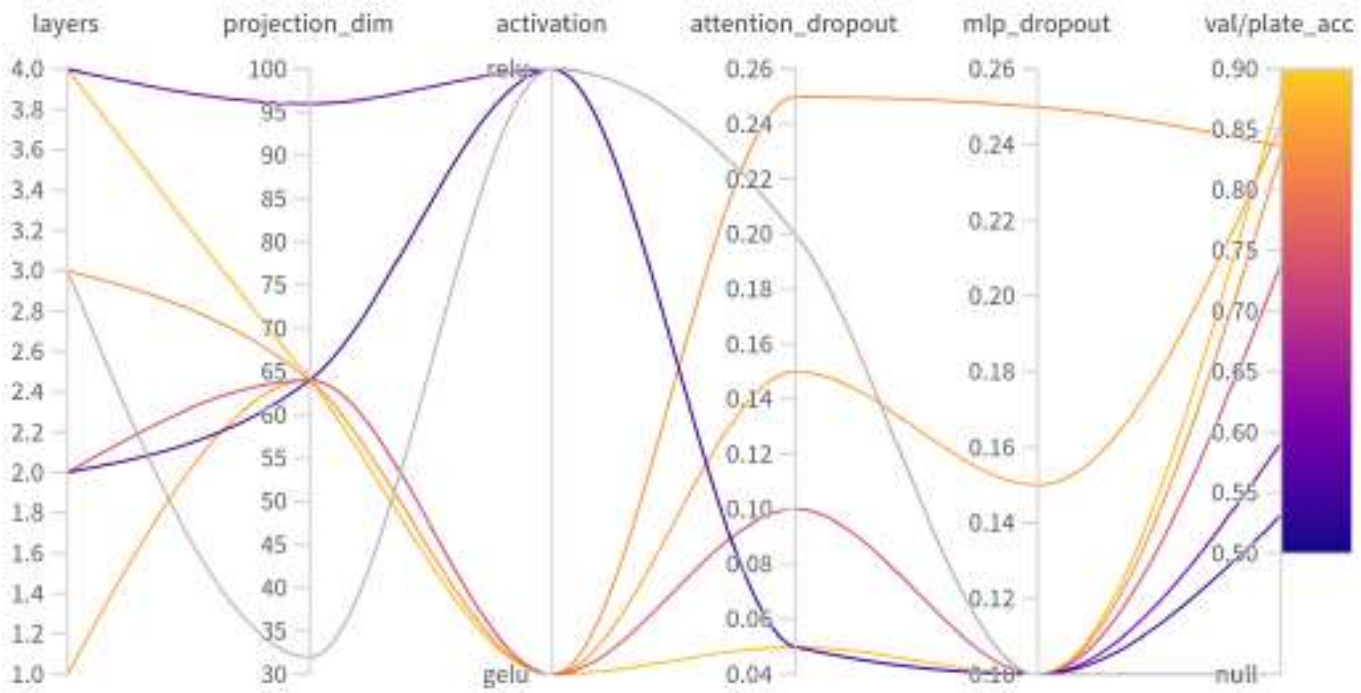


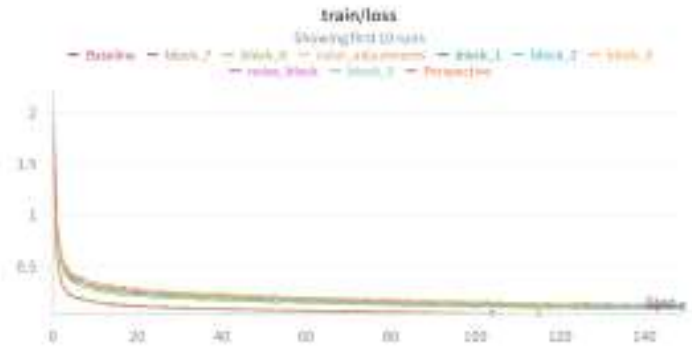
Figure: Hiperparámetros del modelo contra precisión de reconocimiento de placa

Mejor conjunto de hiperparámetros

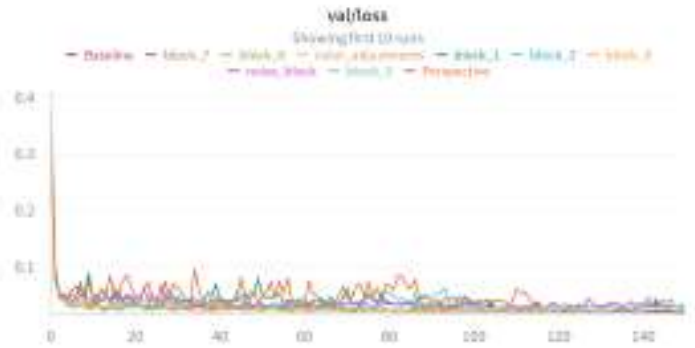
Parámetro	Valor
Capas	4
Cabezas de atención	1
Dimensión de proyección	64
Función de activación	GELU
Caída de atención	0.05
Caída de MLP	0.1
Altura de imagen	64
Ancho de imagen	128
Modo de color	RGB
Tamaño de lote	32
Decaimiento de pesos	0.0005
Tasa de aprendizaje	0.0005

Table: Mejor conjunto de hiperparámetros de entrada, optimizador y modelo.

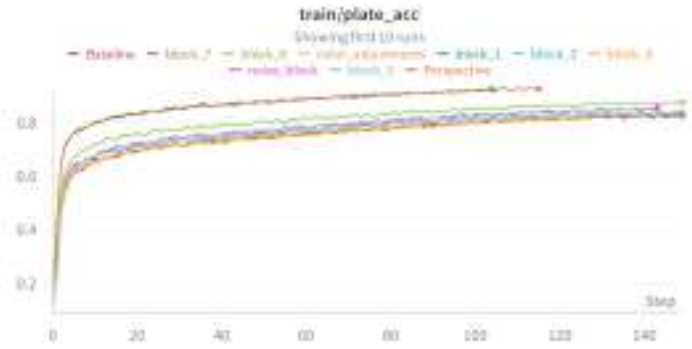
Efecto del aumento de datos: Parte 1



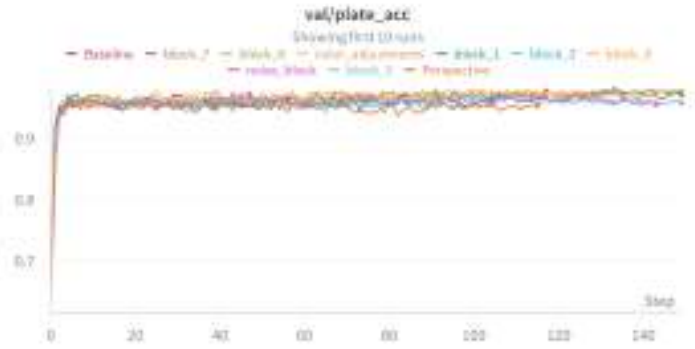
(a) Pérdida en entrenamiento



(b) Pérdida en validación



(c) Precisión de reconocimiento de placa completa en entrenamiento



(d) Precisión de reconocimiento de placa completa en validación

Figure: Métricas de aprendizaje con aumentado de datos

Efecto del aumento de datos: Parte 2

Configuración	**Precisión de validación**	**Δ respecto a base**
Modelo con todos los aumentos (base)	0.9844	—
Sin desenfoques ni ruido	0.9744	–0.0100
Sin distorsiones geométricas	0.9696	–0.0148
Sin brillo ni contraste	0.9712	–0.0132
Sin corrección de perspectiva	0.9647	–0.0196

Análisis de fallo del OCR



(a) Fallo en primera K



(b) Fallo en el 8



(c) Fallo en el 1



(d) Fallo en el segundo 7



(e) Fallo en ambos 5



(f) Fallo completo en placa



(g) Fallo en primer 6 y el 3



(h) Fallo completo



(i) Fallo en la X



(j) Fallo completo



(k) Fallo completo

Figure: Casos de fallo en el reconocimiento de placas

Comparación de resultados OCR

Modelo	Precisión de placa	Precisión de longitud
EasyOCR	0.037	0.037
Fast-Plate-OCR sin ajuste	0.755	0.807
OCR propuesto	0.984	0.997

Table: Comparación de desempeño entre el modelo base y el modelo OCR propuesto.

Rendimiento del sistema completo

Métrica	**Valor medido**
Latencia promedio por cuadro	299.6 ± 69.7 ms
Latencia mínima	174.11 ms
Latencia máxima	430.68 ms
Velocidad promedio	3.84 ± 0.79 FPS
Cuadros procesados	4758
Cuadros con detección	2047 (43.0%)
Videos analizados	13

Table: Resultados de desempeño del sistema integrado (YOLO + Fast-Plate-OCR).

Conclusiones

- Sistema integrado: combinación de YOLO (detección) y Fast-Plate-OCR (reconocimiento) en un flujo unificado, evitando limitaciones de segmentación tradicional.
- Mejora por datos diversos: incluir placas de otros países mejoró la generalización del modelo detector, reduciendo el sobreajuste.
- Aumento de datos efectivo: eliminar tipos de aumento degradó el rendimiento, demostrando su importancia para el OCR.
- Desempeño sobresaliente de subsistemas:
  - YOLO: 93.5% de precisión, mAP@0.5 = 0.946
  - OCR: 98.4% de precisión (vs. 3.7% del modelo base)
- Desempeño del sistema completo:
  - Latencia: 300 ms por cuadro
  - Velocidad: 3.84 FPS sin GPU — adecuado para análisis fuera de línea.
- Objetivos cumplidos: se logró un sistema robusto y preciso de detección y reconocimiento de placas vehiculares.

Recomendaciones

- Ampliar el conjunto de datos de entrenamiento y validación para reducir el sesgo en la detección de placas.
- Revisar y corregir las etiquetas del conjunto de datos, ya que el desempeño se vio afectado por un etiquetado deficiente.
- Incluir en el dataset mayor cantidad de los tipos de placas vehiculares de Costa Rica, para ampliar los escenarios de uso.
- Mejorar el generador sintético de placas, de modo que pueda producir tipos de placas adicionales.
- Profundizar en el estudio de técnicas de aumento de datos, enfocándose en los casos donde el sistema falló.
- Evaluar el rendimiento del sistema completo utilizando modelos optimizados (ONNX) y en el hardware final con aceleración GPU.